

Harness Engineering: What Separates Top Agentic Engineers Right Now

Time	Subtitle	Machine Translation
0s	A term that's popping up more and more in the AI space right now is harness	Un término que está apareciendo cada vez más en el ámbito de la IA es el de
4s	engineering. It's the next big thing for this year, just like context engineering	ingeniería de arneses. Es la próxima gran novedad de este año, al igual que lo fue la ingeniería de contexto el
8s	was for last year, and it is really important. But just like context	año pasado, y es realmente importante. Pero al igual que ocurre con la
13s	engineering, it's starting to turn into this buzzword that people are throwing	ingeniería de contexto, está empezando a convertirse en una palabra de moda que la gente usa
16s	around without really knowing what it means. And so that begs the question, is	sin saber realmente lo que significa. Esto nos lleva a preguntarnos: ¿
20s	this skill or even mindset, like I'll get into in a little bit, worth learning	vale la pena aprender
25s	or adopting? And the answer is yes. And so I want to get into that with you	o adoptar esta habilidad o incluso esta mentalidad, de la que hablaré más adelante? Y la respuesta es sí. Por eso quiero hablarles
29s	today, helping you understand what harness engineering is. There are a	hoy sobre esto, para ayudarlos a comprender qué es la ingeniería de arneses. Tiene
33s	couple of layers to it that are really worth knowing. And so I'm going to break	varias facetas que realmente vale la pena conocer. Así que voy a explicártelo de forma sencilla
37s	this down nice and simple for you in less than 15 minutes. And of course,	y clara en menos de 15 minutos. Y, por supuesto,
41s	like usual, I've got some examples and demos to really make it concrete. All	como siempre, tengo algunos ejemplos y demostraciones para que quede realmente claro. Muy
45s	right, so let's get right into it. Harness engineering is all about	bien, entonces entremos de lleno en materia. La ingeniería de arneses consiste en
48s	building the wrapper around the model. So any agent is the combination of the	construir la envoltura que rodea al modelo. Por lo tanto, cualquier agente es la combinación del
53s	underlying large language model like GPT or Claude and then the wrapper around it	modelo de lenguaje subyacente, como GPT o Claude, y luego la capa que lo envuelve,
58s	that gives it the context and defines your processes. And so I'm mostly going	que le da el contexto y define sus procesos. Por lo tanto, en este video me
1:03	to be focusing on AI coding assistance for this video. But really this idea of	centraré principalmente en la asistencia de codificación mediante IA . Pero en realidad, esta idea de
1:07	harness engineering can be extrapolated out to any agent that you build for	ingeniería de arnés se puede extrapolar a cualquier agente que construyas para cualquier

1:11	anything. And there are really two parts of harness engineering. we have within	propósito. Y en realidad hay dos partes en la ingeniería de arneses. Tenemos dentro de
1:16	an individual AI coding assistant session. And then we have really the	una sesión individual de asistente de codificación de IA . Y aquí es donde realmente se produce la
1:20	real evolution here that I'm more focused on right now. This is combining	verdadera evolución, en la que estoy más centrado ahora mismo. Esto consiste en combinar
1:25	multiple coding agent sessions in a larger workflow to handle a larger task.	varias sesiones de agentes de codificación en un flujo de trabajo más amplio para gestionar una tarea de mayor envergadura.
1:29	And so we'll get there, but I want to start more foundational here. And one	Y así llegaremos, pero quiero empezar por lo más básico. Y algo
1:34	really important thing to understand is that this first idea of harness	realmente importante que hay que entender es que esta primera idea de
1:37	engineering within a single session, a lot of the ideas here are very similar	ingeniería de arnés dentro de una sola sesión, muchas de las ideas aquí son muy similares
1:42	to context engineering. This is a direct evolution of context engineering. How do	a la ingeniería de contexto. Esto representa una evolución directa de la ingeniería de contexto. ¿Cómo
1:47	we give the right ecosystem of context to our coding agent? But there are some	proporcionamos el ecosistema de contexto adecuado a nuestro agente de codificación? Pero hay algunas
1:52	important differences here that I want to key in on. But first of all, I think	diferencias importantes en las que quiero centrarme . Pero antes que nada, creo que
1:55	this diagram explains it really well. We start with the underlying large language	este diagrama lo explica muy bien. Comenzamos con el modelo de lenguaje subyacente a gran escala
1:59	model. This is the reasoning for our agent. And then the first wrapper around	. Este es el razonamiento de nuestro agente. Y entonces, la primera capa que lo envuelve
2:04	it is not something you build yourself. It's actually the tool that you use, the	no es algo que uno mismo construya. En realidad, se trata de la herramienta que uses, del
2:08	coding agent that you choose. And so Claude Code, Codeex, Pi, you name the	agente de codificación que elijas. Y así, Claude Code, Codeex, Pi, y
2:13	millions of coding agents out there. All of them are actually harnesses that a	muchos otros programas de codificación que existen. En realidad, todos ellos son sistemas de sujeción que una
2:18	company has engineered around their model. And so this might not feel like	empresa ha diseñado en torno a su modelo de negocio. Por lo tanto, esto puede no parecer
2:22	harness engineering because you're not defining anything, but you're picking	ingeniería de arneses porque no estás definiendo nada, sino que estás eligiendo
2:25	the harness when you choose the tool. Some people think Claude Code is the	el arnés cuando eliges la herramienta. Algunas personas piensan que Claude Code es el
2:29	best harness for coding. Some people think Codeex is. There's a lot of debate	mejor entorno de programación. Algunas personas piensan que Codeex lo es. Actualmente hay mucho debate al respecto
2:32	right now. But what's even more important than the coding agent you pick	. Pero lo que es aún más importante que el agente de codificación que elijas

2:36	is the AI layer. This is the ultimate wrapper around any coding agent session.	es la capa de IA. Este es el envoltorio definitivo para cualquier sesión de agente de codificación.
2:42	And this is what you get to actually build. And so when we think about what	Y esto es lo que realmente vas a construir. Así pues, cuando pensamos en lo que implica
2:46	goes into the AI layer, it's really defining all of our context and	la capa de IA, se trata realmente de definir todo nuestro contexto y
2:50	processes for our coding agents. So our global rules, our skills and MCP	procesos para nuestros agentes de codificación. Entonces, nuestras reglas globales, nuestras habilidades y
2:55	servers, all the capabilities we give, codebased searching like LSP or	servidores MCP, todas las capacidades que brindamos, búsqueda basada en código como LSP o
2:59	knowledge graphs, our hooks, and our sub aents. really like these six components	grafos de conocimiento, nuestros ganchos y nuestros subagentes. Me gustan mucho estos seis componentes
3:04	that are pretty much built into every single AI coding assistant now makes up	que están prácticamente integrados en todos los asistentes de codificación de IA y que ahora conforman
3:09	your AI layer. So no matter how you want to inject your process or your rules,	tu capa de IA. Así que, independientemente de cómo quieras implementar tu proceso o tus reglas, tendrás que
3:13	you're going to do it through one of these six things. So there are a couple	hacerlo a través de una de estas seis opciones. Así que hay un par
3:17	of articles I really want to lean into here to help you understand harness	de artículos en los que realmente quiero profundizar para ayudarte a comprender la
3:21	engineering. I'll link to them in the description. This first one has an	ingeniería de arneses. Pondré los enlaces en la descripción. Esta primera tiene una
3:24	analogy that I want to zoom in on here. I love this. So on the left hand side we	analogía en la que quiero centrarme aquí. Me encanta esto. Así pues, en el lado izquierdo
3:28	have a representation of what the model can do by itself like claude or GPT. And	tenemos una representación de lo que el modelo puede hacer por sí mismo, como Claude o GPT. Y,
3:33	spoiler it's not that much. We take for granted all of the capabilities that AI	aviso de spoiler, no es tanto. Damos por sentadas todas las capacidades que los
3:38	coding assistants like cloud code and codecs give to the model out of the box.	asistentes de codificación de IA, como el código en la nube y los códecs, aportan al modelo de forma inmediata.
3:42	An LLM by itself. It doesn't have any way to access a file system or get or	Un máster en derecho por sí solo. No tiene forma de acceder a un sistema de archivos ni de obtener o
3:46	run any commands. That's everything that comes with that first harness layer	ejecutar ningún comando. Eso es todo lo que incluye esa primera capa de arnés
3:50	built into the tools that we download and use out of the box. And so that's	integrada en las herramientas que descargamos y usamos de inmediato. Y eso es precisamente lo que
3:54	what these top bridges represent here. It's all of the capabilities that these	representan estos puentes superiores. Se trata de todas las capacidades que estas

3:58	tools give to the model to make it so it can really act as an AI coding	herramientas le otorgan al modelo para que pueda funcionar realmente como un asistente de codificación de IA
4:02	assistant. Right? It's the capabilities plus the system prompt built into these	. ¿Bien? Se trata de las capacidades más la función de aviso del sistema integrada en estas
4:06	tools. And then as we get to the lower bridges here, this is where we start to	herramientas. Y luego, al llegar a los puentes inferiores, es donde empezamos a
4:10	get into that higher level AI layer where we get to define things like the	entrar en esa capa de IA de nivel superior donde podemos definir cosas como los
4:14	MCP servers we use, the skills that we build or incorporate, rules, things like	servidores MCP que usamos, las habilidades que creamos o incorporamos, las reglas, cosas así
4:19	that. even going down to Ralph loops like we'll talk about towards the end of	. incluso llegando a bucles de Ralph, como veremos al final de
4:23	this video when we get into stringing multiple coding agent sessions together.	este vídeo cuando encadenemos varias sesiones de agentes de codificación.
4:27	The ultimate kind of harness engineering. So stay tuned for that. But	El máximo exponente de la ingeniería de arneses. Así que estén atentos. Pero
4:31	the point here is that each of these bridges are tools that allow the large	la cuestión aquí es que cada uno de estos puentes son herramientas que permiten que el gran
4:35	language model to function and act as an AI coding assistant. All right, cool. So	modelo de lenguaje funcione y actúe como un asistente de codificación de IA. Vale, genial.
4:39	with that definition, I now want to address the elephant in the room. The	Con esa definición, ahora quiero abordar el tema que todos evitan. La
4:42	question you might be asking yourself is, Cole, isn't a lot of this here just	pregunta que quizás te estés haciendo es: Cole, ¿no es mucho de esto simplemente
4:47	context engineering? like I thought we were covering this in 2025 and the	ingeniería de contexto? Como pensé que cubriríamos esto en 2025 y la
4:52	answer is actually yes to an extent and that's why I think that harness	respuesta es en realidad sí hasta cierto punto y es por eso que creo que la
4:56	engineering is becoming such a buzzword right now most people don't really	ingeniería de arnés se está convirtiendo en una palabra de moda ahora mismo la mayoría de la gente realmente no
5:00	understand how this is truly an evolution from context engineering	entiende cómo esto es realmente una evolución de la ingeniería de contexto
5:04	that's what I want to argue with you right now and so there are two important	eso es lo que quiero discutir contigo ahora y entonces hay dos
5:08	distinctions so first of all most of the harness around the model like this	distinciones importantes así que en primer lugar la mayor parte del arnés alrededor del modelo como lo
5:13	article outlines it is just context engineering your context injection your	describe este artículo es simplemente ingeniería de contexto su inyección de contexto sus
5:17	actions through tools and MCPs, persistence, observability. The one	acciones a través de herramientas y MCP, persistencia, observabilidad. Lo único
5:21	thing that really is different is control. Like Ralph loops, orchestrating	que realmente es diferente es el control. Como los bucles de Ralph, orquestando

5:25	different coding agent sessions and sub agents. I think that is a true evolution	diferentes sesiones de agentes de codificación y subagentes. Creo que eso es una verdadera evolución
5:29	from sub agents. And so we'll talk about that next. But the other really	a partir de los subagentes. Y hablaremos de eso a continuación. Pero la otra
5:34	important distinction that this article outlines is the skill issue reframe. So	distinción realmente importante que este artículo destaca es el replanteamiento del problema de las habilidades. Como
5:39	I alluded to at the start of the video the fact that harness engineering is	mentoné al principio del video, la ingeniería de dureza
5:43	not just a skill, it's also sort of a a mindset, right? A a reframe. So, the	no es solo una habilidad, sino también una especie de mentalidad, ¿verdad? Un replanteamiento. Entonces, el
5:48	author here says, "There's a pattern I watch engineers fall into. The agent	autor dice: "Hay un patrón en el que veo caer a los ingenieros. El agente
5:51	does something dumb, the engineer blames the model, and the blame gets filed	hace algo tonto, el ingeniero culpa al modelo y la culpa se archiva
5:55	under wait for the next version." As in, you know, Claude screws up here. Well,	bajo la categoría de 'esperar a la próxima versión'. Como en, ya sabes, Claude la lía aquí. Bueno, será
5:59	we better wait for Opus 5 or GPT messes up. Let's wait for GPT6. And, you know,	mejor que esperemos a Opus 5 o GPT lo estropeará . Esperemos a GPT6. Y, la
6:04	personally, I see this all the time as well. I'm also tempted to think this	verdad, yo también lo veo todo el tiempo . Yo también me siento tentado a pensar eso
6:08	myself, and you probably are as well. But the harness engineering mindset	, y probablemente tú también. Pero la mentalidad de la ingeniería de arnés
6:13	rejects that default. And by the way, I call this system evolution. It's very in	rechaza esa opción por defecto. Y, por cierto, a este sistema lo llamo evolución. Está muy en
6:18	line with something that I've been focusing on a lot recently. So here's	intonía con algo en lo que me he estado centrando mucho últimamente. Esto es lo que
6:21	what he says. The failure is usually legible. The agent didn't know about a	dice. El fallo suele ser legible. El agente desconocía la
6:25	convention, so you add it to agents.mmd. Or the agent ran a destructive command,	convención, así que la añades a agents.mmd. O bien el agente ejecutó un comando destructivo,
6:29	so you add a hook that blocks it. Basically, the idea here is every	por lo que se añade un gancho que lo bloquea. Básicamente, la idea es que cada
6:33	mistake becomes a rule. Or the way I like to put it is every mistake becomes	error se convierte en una regla. O, como me gusta decirlo, cada error se convierte en
6:38	an opportunity to improve your harness. improving the security through your	una oportunidad para mejorar tu arnés. mejorar la seguridad a través de sus
6:42	hooks, your processes through updating your skills, anything in your harness so	ganchos, sus procesos mediante la actualización de sus habilidades, cualquier cosa en su arnés para que en
6:47	that the next coding agent session that issue you encountered is less likely to	la próxima sesión del agente de codificación sea menos probable que vuelva a surgir el problema que encontré

6:51	come up. And that is super powerful. That system evolution means that you are	. Y eso es sumamente poderoso. Esa evolución del sistema significa que usted está
6:55	taking ownership and improving the performance of your coding agent over	asumiendo el control y mejorando el rendimiento de su agente de codificación con el
6:59	time with the AI layer that you control over the coding assistant that you	tiempo, gracias a la capa de IA que usted controla sobre el asistente de codificación que ha
7:04	chose. And so really harness engineering is all about claiming that agency,	elegido. En realidad, la ingeniería de control se trata de reivindicar esa autonomía, de
7:08	taking ownership of your system so that when something goes wrong, you're not	tomar posesión de tu sistema para que, cuando algo salga mal, no
7:12	just blaming your AI coding assistant and feeling helpless because things will	culpes simplemente a tu asistente de codificación de IA y te sientas impotente, porque
7:16	come up just like working with human developers. There are going to be	surgirán problemas, al igual que cuando trabajas con desarrolladores humanos. Va a haber
7:19	issues. But we need to make sure that we have a way to learn from that and not	problemas. Pero debemos asegurarnos de tener una manera de aprender de eso y no
7:23	just be at the mercies of the next session not encountering that problem	simplemente estar a merced de que en la próxima sesión no volvamos a encontrarnos con ese problema
7:27	again. We want to be the human steering the system feeding forward. So the	. Queremos ser el ser humano que dirige el sistema y lo impulsa hacia adelante. Entonces, la
7:31	initial generation we have our principles and other kinds of context we	generación inicial tenemos nuestros principios y otros tipos de contexto que
7:35	feed in and then we have our sensors for feedback our hooks our review agents the	alimentamos y luego tenemos nuestros sensores para retroalimentación nuestros ganchos nuestros agentes de revisión las
7:40	skills that we give it for that selfcorrection evolving our AI layer	habilidades que le damos para esa autocorrección evolucionando nuestra capa de IA
7:44	over time the sponsor of today's video is Google Cloud specifically their new	con el tiempo el patrocinador del video de hoy es Google Cloud específicamente su nuevo
7:49	agent CLI and I'm excited for this because nowadays it's optimal to build	agente CLI y estoy emocionado por esto porque hoy en día es óptimo construir
7:54	your agents with other agents right using your AI coding assistants like	sus agentes con otros agentes usando sus asistentes de codificación de IA como
7:58	cloud code and codeex now the easy part is getting the idea for an agent, but	Cloud Code y Codeex ahora la parte fácil es tener la idea para un agente, pero
8:03	actually building it out and deploying it to production, that is a different	realmente construirlo e implementarlo en producción, eso es otra
8:07	beast. But Google has made this so incredibly easy now with their agent	bestia diferente. Pero Google lo ha hecho increíblemente fácil ahora con su
8:11	CLI. It's a collection of skills that I can bring into my coding agent that give	interfaz de línea de comandos para agentes. Se trata de un conjunto de habilidades que puedo incorporar a mi agente de codificación, las cuales le proporcionan
8:16	it full clear instructions on how to build agents with the Google agent SDK	instrucciones claras y completas sobre cómo crear agentes con el SDK de agentes de Google

8:21	and even deploy them to production and monitor them. And so right here in my	e incluso implementarlos en producción y monitorizarlos. Así pues, aquí mismo, en mi
8:24	cloud code, for example, I can say use the agent CLI to build a research agent	código en la nube, por ejemplo, puedo decir que use la interfaz de línea de comandos del agente para crear un agente de investigación
8:29	that searches the web. Obviously a simple example, but it's going to use	que busque en la web. Obviamente es un ejemplo sencillo, pero usar
8:33	the instructions really help you build any agent that you want. Then with the	las instrucciones realmente te ayudará a crear cualquier agente que desees. Luego, con la
8:36	help of the skills, your coding agent will create all of the code. It's	ayuda de sus habilidades, su agente de codificación creará todo el código. Ha superado con
8:39	oneshotted a lot of different tests that I've given it here. And then we also	éxito muchas de las pruebas diferentes que le he realizado aquí. Y luego también
8:43	have our local development environment. We can spin up the agent here so that we	tenemos nuestro entorno de desarrollo local. Podemos poner en marcha el agente aquí para
8:47	can test everything locally with a full chat application before we deploy our	poder probarlo todo localmente con una aplicación de chat completa antes de desplegarlo
8:50	agent. And then when you're ready to take your agent to production, it is a	. Y cuando estés listo para llevar tu agente a producción, solo tendrás que ejecutar un
8:54	single command to deploy your Google agent SDK agent to the Google Cloud.	comando para implementar tu agente del SDK de Google Agent en Google Cloud.
8:59	super easy and your agent gets its own identity in the cloud. You have the	Súper fácil y tu agente obtiene su propia identidad en la nube. Aquí tienes el
9:03	playground here to test it live and you have traces full observability. So	entorno ideal para probarlo en directo y con total visibilidad de los rastros. Tienes
9:07	everything you need for a production deployment, but it's not extremely	todo lo necesario para un despliegue en producción, pero no es extremadamente
9:10	difficult to get all this set up like it used to be. And the best part is the	difícil configurarlo todo como antes. Y lo mejor de todo es que la
9:13	agent CLI is free and open- source. You can take these skills, bring it into any	interfaz de línea de comandos del agente es gratuita y de código abierto. Puedes aprovechar estas habilidades, incorporarlas a cualquier
9:18	coding agent, and see how easy it is right now to build any AI agent. I'll	agente de codificación y comprobar lo fácil que resulta actualmente crear cualquier agente de IA. Incluiré
9:22	have a link in the description. I'd highly recommend checking it out. So I	un enlace en la descripción. Recomendando encarecidamente que le echen un vistazo . Así que
9:26	also have this companion repo for our video giving you a super concrete idea	también tengo este repositorio complementario para nuestro vídeo que te da una idea muy concreta
9:30	of what an AI layer can look like. And this is a really good representation	de cómo puede ser una capa de IA. Y esta es una muy buena representación de
9:34	everything here of the AI layer that I'll bring into and evolve in each of my	todo lo que hay aquí, de la capa de IA que incorporaré y desarrollaré en cada una de mis

9:38	code bases. So I want to cover this quick before we get into the last	bases de código. Así que quiero hablar brevemente de esto antes de entrar en la última
9:42	evolution of harness engineering the really powerful stuff building workflows	evolución de la ingeniería de arneses, las cosas realmente poderosas que construyen flujos de trabajo
9:45	where we are bringing together and orchestrating many coding agent sessions	donde reunimos y orquestamos muchas sesiones de agentes de codificación
9:49	and I have examples for that like with the Ralph loop in this repo as well. And	y tengo ejemplos de eso, como con el bucle de Ralph en este repositorio también. Y
9:54	so I did promise that this video is going to be shorter. So I'm not going to	prometí que este vídeo iba a ser más corto. Así que no voy a
9:57	dive extremely deep into each one of the components of the AI layer, but I do	profundizar demasiado en cada uno de los componentes de la capa de IA, pero
10:01	have a video that I'll link to right here where I cover in more detail the	tengo un vídeo al que enlazaré aquí mismo donde explico con más detalle las
10:05	rules and skills and LSP and hooks, each one of the components. I want to stay	reglas, las habilidades, el LSP y los hooks, cada uno de los componentes. Quiero mantenerme en un
10:09	just really high level, give you some golden nuggets here, and then you can of	nivel muy general, darles algunas ideas clave, y luego, por supuesto, pueden
10:12	course just give this repo to your coding agent and have it help you	simplemente pasarle este repositorio a su agente de codificación y dejar que les ayude a
10:15	implement things and understand everything here. So really the	implementar cosas y a entender todo lo que hay aquí. En realidad, la
10:18	foundation of your AI layer is all of the rules, the constraints and	base de tu capa de IA son todas las reglas, las restricciones y las
10:23	conventions that you want your coding agent to follow, your patterns. And so	convenciones que quieres que siga tu agente de codificación, tus patrones. Y esas son
10:26	that's your global rules and any other kinds of on demand context that you have	sus reglas globales y cualquier otro tipo de contexto bajo demanda que tenga
10:30	as markdown confluence documents, that kind of thing. And then your skills,	como documentos de Markdown Confluence, ese tipo de cosas. Y luego están tus habilidades,
10:34	these are the workflows that you have for your coding agent. Like here's how	estos son los flujos de trabajo que tienes para tu agente de codificación. Así es como
10:37	you wanted to plan, implement, and validate. And I have a separate skill	querías planificar, implementar y validar. Y tengo una habilidad separada
10:41	for each because what I really want to do and I highly highly recommend this is	para cada una porque lo que realmente quiero hacer, y lo recomiendo encarecidamente, es que hagas
10:45	you want to do your planning, implementation, and validation all in	tu planificación, implementación y validación en
10:49	separate coding agent sessions to keep each one of them token efficient and	sesiones separadas del agente de codificación para mantener cada una de ellas lo más eficiente y
10:53	focused. And so each one of these skills is going to output some kind of artifact	enfocada posible. Así pues, cada una de estas habilidades generará algún tipo de resultado que

10:58	so you can use it as a handoff to the next session. And so this is kind of	podrás utilizar como material de apoyo para la siguiente sesión. Así que esto implica
11:03	getting into stringing coding agent sessions together, but we're still	encadenar sesiones de agentes de codificación , pero seguimos
11:06	talking about doing this manually, right? like you'll run the plan and	hablando de hacerlo manualmente, ¿ verdad? como ejecutarás el plan y
11:09	you'll create the plan with the coding agent with one skill and then you'll	crearás el plan con el agente de codificación con una habilidad y luego
11:13	take this markdown and then you'll give it to the next coding agent session for	tomarás este markdown y luego se lo darás a la siguiente sesión del agente de codificación para
11:16	the implement skill, right? You go through that systematically yourself.	la habilidad de implementación, ¿ verdad? Tú mismo debes hacerlo de forma sistemática.
11:20	And so we'll talk about in a little bit how we can really bring all that	Y dentro de un rato hablaremos de cómo podemos integrar todo eso
11:22	together. And then as far as hooks go, these are honestly pretty underused. I	. Y en lo que respecta a los ganchos, la verdad es que están bastante infrautilizados. Me
11:27	love using hooks for a few different things. First of all, for security. So a	encanta usar ganchos para varias cosas diferentes. En primer lugar, por seguridad. Entonces, un
11:31	pre-tool use hook. Basically, this is a piece of code that's going to trigger	gancho para usar antes de usar la herramienta. Básicamente, se trata de un fragmento de código que se activará
11:35	before the coding agent executes any tool call like writing out to a file,	antes de que el agente de codificación ejecute cualquier llamada a una herramienta, como escribir en un archivo o
11:40	running any kind of command. And so, this is where we can build in security	ejecutar cualquier tipo de comando. Así pues, aquí es donde podemos incorporar
11:43	things like not reading files because we really don't want that in the LLM's	medidas de seguridad, como por ejemplo, impedir la lectura de archivos, ya que realmente no queremos eso en el contexto de LLM,
11:47	context or removing directories in a very destructive way, for example. I	o eliminar directorios de forma muy destructiva.
11:52	also like having some kind of stop validation hook. So when the coding	También me gusta tener algún tipo de gancho de validación de parada. Entonces, cuando el
11:56	agent says it's done with the implementation, I want to	agente de codificación dice que ha terminado con la implementación, quiero
11:59	deterministically run a set of tests like are the unit tests, the linting,	ejecutar de forma determinista un conjunto de pruebas como las pruebas unitarias, el análisis estático,
12:03	the type checking, is all that really passing? Cuz if it's not, I want to	la verificación de tipos, ¿ realmente todo eso pasa? Porque si no lo es, quiero
12:07	force the coding agent to iterate on it until it is. And that's what this hook	obligar al agente de codificación a iterar sobre ello hasta que lo sea. Y eso es lo que hace este gancho
12:11	does. And then last but not least, just running a quick lint after every single	. Por último, pero no menos importante, ejecutar un análisis de código rápido después de cada

12:15	file edit is really good just to keep your code base nice and clean, which	edición de archivo es realmente bueno para mantener la base de código limpia y ordenada, lo que
12:19	also helps make your coding agents more reliable in the future. So there you go.	también ayuda a que los agentes de codificación sean más fiables en el futuro. Ahí lo tienes.
12:22	Just a couple of golden nuggets for the AI layer that we have here. And I even	Un par de ideas clave para la capa de IA que tenemos aquí. E incluso
12:26	have instructions in the readme for just running a super basic pit. This is the	tengo instrucciones en el archivo readme para ejecutar un pit súper básico. Este es el
12:30	foundational approach to agentic engineering. So you plan with the plan	enfoque fundamental de la ingeniería de agentes. Así que planificas con la
12:33	skill just sending in the feature that you want. You iterate on the plan. You	habilidad de planificación simplemente enviando la función que deseas. Se va iterando sobre el plan. Usted
12:37	produce that markdown document that you then hand off to the implement skill in	genera ese documento Markdown que luego entrega a la habilidad de implementación en
12:40	a separate coding agent session. You also have your validation strategy for	una sesión de agente de codificación separada. También tienes tu estrategia de validación para que
12:44	the agent to check its own work in the markdown as well. So feel free to try	el agente compruebe su propio trabajo en el formato Markdown. Así que no dudes en probarlo tú
12:49	that out for yourself. But now finally I want to get to the peak evolution of	mismo. Pero ahora, por fin, quiero llegar a la cúspide de la evolución de la
12:54	harness engineering. So I'm going to jump back to the diagram here. Let's	ingeniería de arneses. Así que voy a volver al diagrama. ...Hablemos
12:57	talk about orchestrating coding agent sessions. This is when we can really	de cómo orquestar las sesiones del agente de codificación . Es en este momento cuando realmente podemos
13:01	scale the amount of work that we get done with coding agents. So the main	aumentar la cantidad de trabajo que realizamos con los agentes de codificación. La
13:05	idea here is you don't just want to take a massive task or PRD and hand it to a	idea principal aquí es que no se trata simplemente de tomar una tarea enorme o un PRD y entregárselo a una
13:10	single coding agent session. It's not going to be token efficient and the	sola sesión de agente de codificación. No va a ser eficiente en cuanto al uso de tokens y el
13:14	underlying large language model in the harness is going to be completely	modelo de lenguaje subyacente, que es muy grande, se verá completamente
13:18	overwhelmed. It does not matter how good the AI layer is that you created here	desbordado. No importa lo buena que sea la capa de IA que hayas creado aquí
13:23	with things like your skills and rules. If you send too much into the LLM at	con cosas como tus habilidades y reglas. Si se invierte demasiado en el máster en derecho (LLM) a la
13:27	once, it is going to fall flat on its face. And so what we're doing here,	vez, fracasará estrepitosamente . Lo que estamos haciendo aquí, al
13:31	orchestrating many coding agent sessions together, is we're giving each coding	coordinar muchas sesiones de agentes de codificación , es asignar a cada

13:35	agent a very focused task. And so these can be sub agents as well, but like	agente de codificación una tarea muy específica. Así pues, estos también pueden ser subagentes, pero como
13:40	you'll see in the real loop, it's actual coding agent sessions that are handing	verás en el bucle real, son sesiones de agentes de codificación reales las que se pasan las
13:43	things off to each other. So we can explore the implementation that comes in	cosas entre sí. Así podemos explorar la implementación que surge
13:47	from a user requirement. Have one agent that writes the plan. Send that plan	de un requisito del usuario. Designar a un agente para que redacte el plan. Envía ese
13:52	artifact into an implementation. And then for example, this is just an	artefacto del plan a una implementación. Y luego, por ejemplo, este es solo un
13:56	example harness, but we could have many code review agents running in parallel.	ejemplo de configuración, pero podríamos tener muchos agentes de revisión de código ejecutándose en paralelo.
14:00	This one focuses on security. This one correctness of the implementation. And	Este se centra en la seguridad. Esta es la corrección de la implementación. Y
14:03	this one making sure it's as simple as it can be. And then if everything	este se asegura de que sea lo más simple posible . Y si todo
14:07	passes, you create the pull request. Otherwise, you would iterate and keep	sale bien, creas la solicitud de extracción. De lo contrario, tendrías que iterar y seguir
14:10	working on the implementation. And you can do all this manually like I was	trabajando en la implementación. Y puedes hacer todo esto manualmente, como te
14:14	talking about earlier. We can go to cloud code once and create the plan and	comenté antes. Podemos acceder al código en la nube una vez, crear el plan y
14:17	then open up another cloud code and do the implementation. But the real power	luego abrir otro código en la nube para realizar la implementación. Pero la verdadera ventaja
14:21	with harness engineering here is we can automate all of this. We can create a	de la ingeniería de arneses en este caso es que podemos automatizar todo esto. Podemos crear un
14:26	system that automatically hooks together all these coding agent sessions with the	sistema que conecte automáticamente todas estas sesiones de agentes de codificación con los
14:31	handoff documents and creating the poll requests and everything like that. And	documentos de traspaso, creando las solicitudes de sondeo y todo lo demás. Y
14:35	that's what the RA loop does. So let's go back to our example repo here. I want	eso es lo que hace el bucle RA. Así que volvamos a nuestro repositorio de ejemplo. Quiero
14:38	to show you what this actually looks like. So the Ralph loop is just one	mostrarte cómo se ve esto en realidad . Así pues, el bucle de Ralph es solo un
14:42	example of an agent harness. But Jeffrey Huntley, the creator of Ralph, he really	ejemplo de un arnés de agente. Pero Jeffrey Huntley, el creador de Ralph, es sin duda
14:46	is one of the pioneers here. This is one of the first examples showing in a very	uno de los pioneros en este campo. Este es uno de los primeros ejemplos que muestra, de
14:51	basic sense how we can automate stringing together many instances of	forma muy básica, cómo podemos automatizar la concatenación de muchas instancias de
14:55	cloud code, codecs. I mean you could do this with any coding assistant because	código en la nube y códecs. Quiero decir, podrías hacer esto con cualquier asistente de

	codificación porque
14:59	basically all it is, I'm not going to get too technical here, but I just want básicamente todo lo que es, no voy a ponerme demasiado técnico aquí, pero solo quiero
15:01	to show you a little bit is we have a simple script. This can be a Python mostrarte un poco es que tenemos un script simple. Puede ser un
15:05	script, it can be a bash script. I'm not going to go into the code here, but script de Python o un script de Bash. No voy a entrar en detalles sobre el código, pero
15:09	essentially you give it a larger scope of work, like a massive PRD, and it's básicamente le asignas un ámbito de trabajo más amplio, como un PRD enorme, y se
15:13	going to be responsible for splitting that up into individual tasks and then encargará de dividirlo en tareas individuales y luego
15:17	running coding agent sessions to handle them one at a time until everything is ejecutar sesiones de agentes de codificación para gestionarlas una a una hasta que todo esté
15:21	done. And so you give it a prompt. This is the user input here, like these are terminado. Y entonces le das una pista. Esta es la entrada del usuario aquí, como estos son
15:25	the different items that I want to build in the spec. And then it's going to los diferentes elementos que quiero construir en la especificación. Y luego
15:29	produce a plan here. This is the fix plan. So like this is what it's going to elaborará un plan. Este es el plan de reparación. Entonces, esto es lo que va a
15:32	do in iteration one of the loop, iteration two, iteration three. It's hacer en la iteración uno del bucle, iteración dos, iteración tres.
15:35	going to keep working and kind of like build up a log as the different cloud Seguirá funcionando y, de alguna manera, irá creando un registro a medida que se ejecuten las diferentes
15:39	code sessions here are running. And then when it decides it's done, it's going to sesiones de código en la nube. Y cuando decida que ha terminado,
15:43	produce some kind of indicator of that. Like here I'm using a done.ext. And so generará algún tipo de indicador de ello. Como aquí estoy usando un done.ext. Y aquí
15:47	this is where it decides like all right, all eight spec items from the original es donde decide que, bueno, los ocho elementos de especificación de la
15:51	prompt are done. We are satisfied. We can now exit the loop. And that's the solicitud original están listos. Estamos satisfechos. Ahora podemos salir del bucle. Y esa es la
15:54	only condition. The only way that we can exit the main while loop here is if we única condición. La única forma en que podemos salir del bucle while principal aquí es si
16:00	have this done.ext text and the coding agent is confident that the tenemos este texto done.ext y el agente de codificación está seguro de que la
16:03	implementation is done and all the validation is there. And so just trying implementación está hecha y toda la validación está presente. Y solo intento
16:07	to show you real loop to give you one example of a harness. But you can see mostrarles un bucle real para darles un ejemplo de un arnés. Pero aquí se puede apreciar
16:11	the idea here of we are using many coding agent sessions to keep each one la idea: estamos utilizando muchas sesiones de agente de codificación para mantener a cada uno
16:16	very very focused but also we're automating it so we don't have to muy concentrado, pero también lo estamos automatizando para no tener que

16:19	babysit our coding agent as we're handling these longer tasks. This really	supervisar constantemente a nuestro agente de codificación mientras realizamos estas tareas más largas. Este
16:23	is the future of agentic engineering. Building these harnesses to handle	es realmente el futuro de la ingeniería automatizada. Diseñamos estos sistemas para gestionar proyectos de
16:28	larger scopes of work as the models and the underlying tools are getting more	mayor envergadura a medida que los modelos y las herramientas subyacentes se vuelven más
16:32	powerful. Like this is the way. And so lean into this here. I mean there's so	potentes. Así es como se hace. Así que, aprovecha esto. Me refiero a que existen
16:36	many resources out there for harness engineering. And then there's Archon, my	muchísimos recursos para la ingeniería de arneses. Y luego está Archon, mi
16:40	open-source harness builder. Free to use. This is the easiest way to get	creador de arneses de código abierto. De uso gratuito. Esta es la forma más sencilla de
16:44	started with Agentic Engineering. Building your own harnesses like the Ral	empezar con la ingeniería agénica. Construye tus propios arneses como el Ral
16:47	Flute, but more custom to you, your exact process and software development	Flute, pero más personalizados según tus necesidades, tu proceso exacto y tu
16:51	life cycle. So, I'd highly recommend checking this out. Otherwise, I hope	ciclo de vida de desarrollo de software. Por lo tanto, recomiendo encarecidamente que le echen un vistazo . Por lo demás, espero que
16:54	this video was helpful for you in general, just understanding what is	este vídeo te haya resultado útil en general para comprender qué es la
16:58	harness engineering, what's the fluff, what's really worth knowing. If you	ingeniería de arneses, qué es lo superfluo y qué es lo que realmente vale la pena saber. Si te ha
17:01	found this useful in any way, I would really appreciate a like and a	resultado útil de alguna manera, te agradecería mucho que le dieras a "me gusta" y te
17:05	subscribe. And with that, I will see you in the next	suscribieras. Y con esto, nos vemos en la próxima.